

Системы хранения и обработки данных

Силлабус

Семестр	1
Зачетные единицы	5 ЗЕ
Длительность	3 ноября — 14 декабря (6 недель)
Аттестация	Дифференцированный зачет

[Аннотация](#)

[Цель дисциплины](#)

[Преподаватели](#)

[Результаты обучения](#)

[Логика прохождения](#)

[Тематический план](#)

[Практика](#)

[Аттестация](#)

Аннотация

Дисциплина направлена на изучение современных технологий хранения, обработки и управления данными, реляционных (PostgreSQL) и нереляционных (MongoDB) СУБД, распределенных систем (Hadoop, Spark), а также инструментов ETL и оркестрации (Apache Airflow). После ее прохождения вы освоите принципы проектирования масштабируемых хранилищ, оптимизации запросов и автоматизации процессов обработки данных.

Цель дисциплины

Сформировать компетенции в области проектирования, реализации и администрирования систем хранения и обработки данных с использованием современных технологий, включая реляционные и NoSQL-СУБД, распределенные вычисления и инструменты оркестрации данных.

Преподаватели



Светлана Медведева

Автор дисциплины

- Преподаватель кафедры информатики и вычислительной математики МФТИ, Физтех.
- Data Analyst в R-labs, Ramax International.
- Ранее работала: Coelus, SAS Institute, Huawei и Лаборатории теоретической физики им. Н. Н. Боголюбова, Объединенный институт ядерных исследований (ОИЯИ), Дубна.



Сона Геворгян

Автор дисциплины, ведет семинары

- Руководитель направления в ПАО Сбербанк.

Образование:

- МФТИ, ФПМИ, Машинное обучение и анализ данных.
- МАИ, Фундаментальная информатика и информационные технологии.



Андрей Куртасов

Автор дисциплины

Главный системный аналитик в ООО «Техсофт», преподаватель дисциплин «Прикладная аналитика данных» и «Программирование на Python» в рамках программы Цифровых кафедр в МФТИ.

Образование:

- Вологодский государственный технический университет;
- аспирантура на кафедре информационных систем и технологий.

Пререквизиты и постреквизиты

Какие дисциплины помогут в освоении:

- Программирование на Python.

В каких дисциплинах понадобится далее:

- Инжиниринг данных.
- Инструменты Big Data.

Результаты обучения

После прохождения дисциплины вы будете уметь:

- работать с реляционными БД на примере PostgreSQL: создавать БД, создавать таблицы и заполнять их данными;
- изменять структуру таблиц, добавлять новые записи и изменять существующие записи;
- писать SQL-запросы на выборку данных по условиям;
- извлекать данные из нескольких таблиц с помощью джойнов и условий на выборки;
- группировать данные в таблицах и применять оконные функции;

- работать с Hive и Spark SQL для анализа больших данных;
- оптимизировать запросы в распределенных средах;
- проектировать ETL-процессы для структурированных / неструктурированных данных;
- создавать DAG-пайплайны в Airflow, настраивать расписания;
- интегрировать Airflow с Hadoop, Spark.

Какие профессиональные задачи сможете решать:

- Выбор наиболее подходящего типа БД в зависимости от решаемой задачи (использование реляционных БД для данных, представимых в виде таблиц и колоночных, — в случае большого объема данных и большого числа запросов к столбцам таблиц).
- Создание БД и заполнение ее таблицами заданной структуры.
- Выбор типа столбцов в таблице для хранения той или иной информации. Выборка строк таблиц по нескольким условиям, объединенным логическими операторами.
- Извлечение данных из связанных между собой таблиц и написание сложных запросов.
- Применение оконных функций для расчета накопительного итога, вычисления среднего значения с заданным окном усреднения, нахождение первого/последнего значения столбца для заданной партиции.
- Применение MongoDB для управления базами данных.

Логика прохождения

Программа дисциплины состоит из нескольких модулей. Каждый модуль включает в себя:

- материал на учебной платформе для самостоятельного изучения в удобное вам время, но в рамках длительности дисциплины;
- синхронные занятия с преподавателем, даты и время которых указываются в общем расписании вашего потока.

Материал на платформе:

- видеолекции;

- презентации и конспекты;
- домашние задания.

Синхронные занятия проходят в следующих форматах:

- **Вебинар.** Краткое повторение теории, решение практических задач от преподавателя, разбор решений, групповые работы. Весь материал преподаватель передает на занятии. Записи вебинаров выкладываются в доступ в течение нескольких дней.
- **Дополнительный вебинар повышенной сложности.** Посещение данного формата занятий свободное. Решение дополнительных практических задач от преподавателя, разбор решений, групповые работы. Весь материал преподаватель передает на занятии. Записи вебинаров выкладываются в доступ в течение нескольких дней.

Тематический план

Модуль 1. Введение в БД

Темы:

1. Что такое БД и каких типов они бывают.
2. Основные элементы реляционных БД.
3. САР-теорема и нормализация.
4. СУБД.
5. Понятие Git, работа с Github.

Синхронные занятия:

1. Практикум «Проектирование и нормализация БД».
2. Практикум «PostgreSQL».
3. Дополнительный практикум повышенного уровня «Проектирование хранилища данных по методологии Data Vault 2.0».

Домашнее задание: создание и нормализация базы данных.

После прохождения модуля вы сможете:

- рассказать, что такое БД и для чего они нужны;

- описать, какие модели данных бывают и по каким критериям можно проводить классификацию БД;
- объяснить, в чем отличие между различными типами БД;
- рассказать, из каких элементов состоит реляционная БД;
- объяснить, что такое индексирование и для чего оно используется в реляционных БД;
- устранять избыточность данных в БД путем нормализации;
- рассказать о СУБД и привести примеры СУБД для реляционных БД.

Модуль 2. PostgreSQL как пример СУБД для работы с реляционными БД

Темы:

1. Основы работы с PostgreSQL.
2. Типы операторов.
3. Простые выборки по условию.
4. Выборки по нескольким условиям.
5. Вложенные запросы.
6. Множественное объединение.

Синхронные занятия:

1. Практикум «PostgreSQL: запросы».
2. Практикум «PostgreSQL: объединение таблиц».
3. Дополнительный практикум повышенного уровня «PostgreSQL: основные операторы, группировки данных и оконные функции».

Домашнее задание: основные операторы PostgreSQL.

После прохождения модуля вы сможете:

- подключаться к БД через Python и PostgreSQL;
- добавлять, изменять, удалять записи в таблице и извлекать данные из таблиц по заданному условию;

- писать вложенные запросы.

Модуль 3. Объединение таблиц, группировка данных и оконные функции

Темы:

1. Типы объединений таблиц.
2. Группировка данных и агрегатные функции.
3. Оконные функции.
4. Ранжирующие оконные функции.
5. Агрегирующие оконные функции.
6. Функции смещения.
7. Аналитические функции.
8. Временные таблицы.
9. План запроса.

Синхронные занятия:

1. Практикум «Группировка данных».
2. Практикум «Оконные функции».
3. Дополнительный практикум повышенного уровня «Транзакции в PostgreSQL, администрирование».

Домашнее задание: объединение таблиц и оконные функции.

После прохождения модуля вы сможете:

- рассказать, какие типы объединения таблиц есть в SQL;
- писать вложенные запросы;
- объяснить, как просмотреть порядок выполнения операций в SQL-запросе;
- группировать данные с помощью GROUP BY;
- применять оконные функции;

- работать с табличными выражениями, временными таблицами и представлениями.

Модуль 4. NoSQL

Темы:

1. Введение в концепцию NoSQL.
2. Документориентированные базы данных.
3. Базовые операции с данными в MongoDB.
4. Подключение к MongoDB из Python.
5. Объединение, группировка и агрегация данных в MongoDB.

Синхронные занятия:

1. Практикум «Нереляционные БД, CRUD-операции».
2. Практикум «Конвейер по агрегации данных».
3. Дополнительный практикум повышенного уровня «Дополнительные функции MongoDB».

Домашнее задание: агрегация данных в MongoDB.

После прохождения модуля вы сможете:

- подключаться к MongoDB через Python;
- создавать, удалять базы данных;
- работать с коллекциями;
- выполнять CRUD-операции;
- объединять датасеты;
- создавать конвейеры (pipeline) для агрегации данных;
- фильтровать данные (\$match) по условиям;
- агрегировать данные (\$group/\$unwind).

Модуль 5. Экосистема Hadoop

Темы:

1. Основные компоненты и архитектура.
2. Hadoop Distributed File System (HDFS).
3. Структура и особенности форматов JSON, CSV, Avro, Parquet и ORC.
4. Docker и контейнеризация.
5. Apache Hive.
6. Apache Spark.

Синхронные занятия:

1. Практикум «Таблицы и запросы в Hive».
2. Практикум «Таблицы и запросы в Spark».
3. Дополнительный практикум повышенного уровня «План запроса, конфигури для Spark-приложения».

Домашнее задание: анализ данных на Spark SQL.

После прохождения модуля вы сможете:

- понимать архитектуру HDFS, MapReduce, Spark;
- работать с Hive и Spark SQL для анализа данных;
- загружать файлы в HDFS;
- создавать таблицы над ними;
- писать запросы на Hive SQL;
- читать данные из файлов на Spark;
- писать запросы на Spark SQL;
- оптимизировать запросы в распределенных средах.

Модуль 6. Apache Airflow

Темы:

1. ETL vs ELT: теоретические основы.
2. Airflow: введение, архитектура и веб-интерфейс.
3. Интеграция с другими системами.
4. Создание пайплайна.

Синхронные занятия:

1. Практикум «PostgreSQL и Spark».
2. Практикум «Пайплайн и расписание».
3. Дополнительный практикум повышенного уровня «Дополнительные возможности Airflow».

Домашнее задание: автоматизация пайплайна.

После прохождения модуля вы сможете:

- проектировать ETL-процессы для структурированных и неструктурированных данных;
- создавать DAG-пайплайны в Airflow, настраивать расписания;
- интегрировать Airflow с Hadoop, Spark.

Практика

Форматы практических заданий на дисциплине:

- задания для самопроверки;
- домашнее задание 1: создание и нормализация базы данных;
- домашнее задание 2: основные операторы PostgreSQL;
- домашнее задание 3: объединение таблиц и оконные функции;
- домашнее задание 4: агрегация данных в MongoDB;
- домашнее задание 5: анализ данных на Spark;

- домашнее задание 6: автоматизация пайплайна.

Аттестация

Общая информация:

- Дисциплина заканчивается дифференцированным зачетом.
- Итоговая оценка складывается из накопленной (70%) и оценки за диф. зачет (30%).
- Для получения «автомата» по дисциплине вам нужно получить не менее 30% от итоговой оценки (3 баллов).

Формулы оценивания:

Накопленный балл:

$$\text{ДЗ 1} * 0.2 + \text{ДЗ 2} * 0.1 + \text{ДЗ 3} * 0.1 + \text{ДЗ 4} * 0.2 + \text{ДЗ 5} * 0.2 + \text{ДЗ 6} * 0.2$$

Итоговый балл:

$$\text{Накопленный балл} * 0.7 + \text{балл за диф. зачет} \\ (\text{решение задачи} * 0.1 + \text{устный ответ на зачет} * 0.2)$$

Из чего складывается накопленная оценка:

Элемент контроля	Задание	Вес от накопленной оценки
Домашнее задание	ДЗ 1	0.2
	ДЗ 2	0.1
	ДЗ 3	0.1
	ДЗ 4	0.2
	ДЗ 5	0.2
	ДЗ 6	0.2

Зачет состоит из двух частей: устной и письменной. Письменная часть:

решение задач по базам данных, Hadoop, Spark. На выполнение отводится 4 часа. Устная часть: ответ на теоретический вопрос по материалам дисциплины.

Балльная система:

Проценты	Баллы	Оценка
95–100	10	Отлично
85–94	9	
75–84	8	
65–74	7	Хорошо
55–64	6	
45–54	5	
35–44	4	Удовлетворительно
25–34	3	
15–24	2	Неудовлетворительно
0–14	1	